

Beschreiben Sie kurz und allgemein, das klassische Klassifikationsproblem beim Data Mining bzw. beim maschinellen Lernen.

Wie unterscheidet sich das klassische Regressionsproblem vom Klassifikationsproblem beim Data Mining bzw. beim maschinellen Lernen?

Wodurch zeichnen sich Lernprobleme auf Zeitreihen (Time Series) besonders aus?

Nennen Sie drei sogenannte "überwachte" Lernverfahren, und nennen Sie kurz die mathematischen bzw. informatischen Theorien, auf denen Sie basieren.

Nennen Sie die drei wichtigsten Phasen beim Data Mining-Prozess, und beschreiben Sie kurz ihre Funktion.

Was sind die beiden Hauptnachteile während der Nutzungsphase eines kNN-Klassifikators, wenn man kNN (in naiver Form) praktisch einsetzt?

Nennen Sie kurz zwei Maßnahmen, die es ermöglichen, Support Vektor Maschinen auch bei nicht linear separierbaren binären Klassifikationsproblemen einzusetzen.

Support Vektor Maschinen eignen sich zunächst nur für binäre Klassifikationsprobleme (also Probleme mit nur zwei Klassen). Beschreiben kurz einen Ansatz, wie SVMs auch für den Fall von n Klassen genutzt werden können.

Was ist die wichtigste Grundregel, die bei der Auswahl von Test- und Trainingsdaten im Rahmen der Validierung beachtet werden sollte?

Beschreiben Sie kurz, wie die sogenannte n -fache Kreuzvalidierung funktioniert.

Was versteht man unter Stratifikation im Zusammenhang mit der Validierung?

Erklären Sie, wie prinzipiell das erwartete Größenverhältnis der Test- und Trainingsdatenmenge von ca. 27% zu ca. 63% bei der Bootstrap-Validierung entsteht. Hinweis: Die mathematische Formel für das erwartete Verhältnis von Test- und Trainingsdatengröße brauchen Sie dabei nicht herzuleiten.

Geben Sie die Definition von Precision (Präzision) und Recall (Rücklauf) auf Basis der Kenngrößen TP (true positive), FP (false positive), TN (true negative) und FN (false negative) entsprechend dem Aufbau einer Vertauschungsmatrix an.

Angenommen Sie haben gestern aus einem Lehrbuch heraus verstanden, wie ein populäres aber kompliziertes maschinelles Lernverfahren funktioniert. Das Lehrbuch beschreibt auch grob den Algorithmus

des Verfahrens. Sie wollen das Verfahren nun möglichst schnell und kostengünstig ausprobieren und dabei mit ihren Forschungsdaten aus einer SQL-Datenbank experimentieren. Welche prinzipielle(n) Vorgehensweise(n) bietet/bieten sich an?

Nennen Sie zwei sogenannte "unüberwachte" Lernverfahren, und nennen Sie kurz die Ziele und die Ansätze, auf denen Sie basieren.

Nennen Sie drei Beispiele für die Anwendbarkeit des Page Rank-Verfahrens in der Praxis. Geben Sie für jedes Beispiel kurz an, wie sich dabei der gerichtete Graph ergibt, auf dem das Page Rank-Verfahren aufsetzt.

Beschreiben Sie kurz und prägnant, wie das Meta-Lernverfahren "Bootstrap-Aggregation" (Bagging) funktioniert.

Ein Naiver Bayes-Klassifikator arbeitet üblicher Weise über nominellen Quellattributen. Nennen Sie zwei verschiedene Maßnahmen, wie man einen Naiven Bayes-Klassifikator indirekt dennoch auf reellwertigen Quellattributen trainieren kann. Beschreiben Sie diese Maßnahmen.

Beschreiben Sie über eine mathematische Formel, wie das Gütemaß "Sum of Squared-Error" (SSE) zur Bewertung der Qualität einer Clusterung allgemein berechnet wird.

Beim k-Means-Clustering ist die Struktur der entstehenden Cluster abhängig von der Wahl der initialen Cluster-Zentren. Für eine "gute" Wahl der initialen Cluster-Zentren gibt es aber oft keine brauchbare Heuristik. Wie kann man sicherstellen, dass trotz dieser Tatsache optimale Cluster-Zentren hinsichtlich des Gütemaßes SSE gefunden werden?

Was ist der mögliche Wertebereich für ein Feature einer SVM?

Wie lautet die Testfunktion für eine SVM ohne Kernel, d.h. wie stellt man fest, ob ein Testdatensatz beim binären Klassifikationsproblem zur Positiv- oder Negativklasse gehört?

Wie zeigt sich das Problem der Überanpassung im Rahmen einer Validierung?

Wozu dient die Loss-Funktion (oder Verlust-Funktion) bei Neuronalen Netzen?

Beschreiben Sie kurz: Wie funktioniert Bootstrap-Aggregation (auch "Bagging" genannt) als klassifizierendes Lernverfahren?

Mit welchen Maßnahmen kann man der sog. Unteranpassung (Underfitting) entgegenwirken?

Mit welchen Maßnahmen kann man der sog. Überanpassung (Overfitting) entgegenwirken?

Beschreiben Sie den Aufbau eines Perzeptrons. Geben Sie dazu die mögliche Ein- und Ausgabe an und beschreiben Sie, wie die Ausgabe mathematisch aus der Eingabe berechnet wird.

Zeichnen Sie den schematischen Aufbau eines Neuronalen Netzes zur Abbildung der Funktion XOR mit einer minimalen Anzahl von Perzeptronen. Geben Sie jeweils den Bias, die Kantengewichte und die Aktivierungsfunktion für die Perzeptronen an.

Was versteht man unter „Early Stopping“ (frühes Beenden) im Zusammenhang mit dem Training von Neuronalen Netzen?

Geben Sie als Formel an: Wieviele Trainingsparameter hat ein Feed Forward Netz bestehend aus drei Schichten mit n_i Perzeptronen pro Schicht i für $i = 1, 2, 3$, wenn die Neuronen zwischen aufeinanderfolgenden Schichten jeweils voll verknüpft sind? Dabei sei n_1 die Eingabeschicht. Begründen Sie Ihre Antwort kurz.

Wie erstellt man Lernkurven im Rahmen von Validierung und Test? Wozu dienen sie hauptsächlich?

Geben Sie den Aufbau einer Vertauschungsmatrix (Confusion Matrix) für die binäre Klassifikation an. Wie heißen die vier Felder der Matrix jeweils? Geben Sie auf Basis der Felder die Berechnungsformel für die Sensitivität (Sensitivity) an.

Beim k-Means-Clustering ist eine "gute" Wahl für die Anzahl der Cluster k im Vorhinein oft nicht bekannt. Beschreiben Sie ein Verfahren, mit dem man geeignete Kandidaten für k finden kann (ohne auf hierarchische Clustering zurückzugreifen).

Erklären Sie die Funktionsweise der Maximum Likelihood Methode für das Maximum-Likelihood-Lernen anhand der entsprechenden Formel aus der Vorlesung: $\theta_* = \arg\max_{\theta} P(D|\theta)$?

Beantworten Sie kurz: Wodurch zeichnet sich das Verfahren "Random Forest" als spezielles Bagging-Verfahren aus?

Beschreiben Sie kurz, wie der sogenannte Bootstrap funktioniert.